

Laporan Akhir Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Muhammad Ramadhan Albaary Putra (24031554161)
Anggota 1	Muslim Fazlur Rohman (24031554154)
Anggota 2	Kafka Praya Firmansyah (24031554182)
URL Github	https://github.com/Albaary/Project-Machine-Learning

Informasi Umum Proyek

Judul	Klasifikasi Glaukoma pada Citra Retina Menggunakan MobileNetV3 sebagai feature extraction dan Multilayer Perceptron (MLP)
Topik	Kesehatan
Pilihan Rumusan Masalah	Pemanfaatan AI dan Big Data Kesehatan
Revisi?	Ya / Tidak

Pendahuluan

Latar belakang
(≥ 250 kata)

Glaukoma merupakan salah satu penyakit mata kronis yang menjadi penyebab utama kebutaan permanen di dunia. Penyakit ini terjadi akibat kerusakan saraf optik yang berlangsung secara progresif dan umumnya berkembang tanpa gejala yang jelas pada tahap awal. Kondisi tersebut menyebabkan banyak penderita baru menyadari adanya gangguan penglihatan ketika kerusakan saraf optik sudah cukup parah dan sulit dipulihkan. Oleh karena itu, deteksi dini glaukoma menjadi langkah yang sangat penting untuk mengurangi risiko kehilangan penglihatan yang lebih lanjut. Dalam praktik klinis, diagnosis glaukoma umumnya dilakukan melalui pemeriksaan kondisi saraf optik dan retina menggunakan citra fundus. Namun, proses identifikasi secara manual masih memiliki berbagai tantangan karena memerlukan pengalaman dan ketelitian dari dokter spesialis mata. Selain itu, perbedaan karakteristik retina antar pasien, variasi kualitas citra, serta perubahan visual akibat glaukoma yang sering kali bersifat halus menyebabkan proses diagnosis menjadi lebih kompleks. Hemelings et al. (2021) menunjukkan bahwa karakteristik glaukoma tidak hanya ditemukan pada area saraf optik, tetapi juga dapat muncul pada bagian retina lainnya sehingga proses interpretasi citra menjadi semakin menantang. Kondisi ini menunjukkan perlunya pendekatan yang mampu membantu proses analisis citra retina secara lebih objektif dan konsisten.

Perkembangan Artificial Intelligence (AI) dan computer vision memberikan peluang untuk membantu proses diagnosis penyakit berbasis citra medis secara otomatis. Salah satu metode yang banyak digunakan adalah deep learning karena mampu mempelajari pola dan fitur visual langsung dari data citra tanpa memerlukan proses ekstraksi fitur secara manual. Pada bidang oftalmologi, berbagai penelitian telah menunjukkan bahwa pendekatan deep learning mampu memberikan performa yang baik dalam deteksi glaukoma menggunakan citra fundus retina. Gheisari et al. (2021) menunjukkan bahwa kombinasi arsitektur deep learning mampu meningkatkan kemampuan deteksi glaukoma secara signifikan. Penelitian Hemelings et al. (2021) juga menunjukkan bahwa model deep learning dapat mengenali karakteristik

	glaukoma dari citra retina dengan performa yang baik. Selain itu, penelitian Yi et al. (2023) dan Zhang et al. (2022) menunjukkan bahwa pendekatan transfer learning efektif digunakan pada klasifikasi glaukoma karena mampu memanfaatkan pengetahuan dari model yang telah dilatih pada dataset berskala besar untuk meningkatkan performa pada data medis yang relatif terbatas. Berdasarkan temuan tersebut, penelitian ini menggunakan MobileNetV3 sebagai feature extraction dan Multilayer Perceptron (MLP) sebagai classifier untuk membedakan citra retina glaukoma dan non-glaukoma. MobileNetV3 dipilih karena mampu menghasilkan representasi fitur visual yang informatif melalui pendekatan transfer learning, sedangkan MLP digunakan untuk mempelajari pola klasifikasi berdasarkan fitur yang telah diekstraksi. Dengan memanfaatkan kombinasi kedua metode tersebut, penelitian ini diharapkan dapat mendukung pengembangan sistem klasifikasi glaukoma yang lebih efektif serta menjadi salah satu bentuk pemanfaatan AI dalam membantu deteksi dini penyakit mata berbasis citra retina.
Rumusan masalah dan tujuan	Rumusan Masalah Glaukoma merupakan salah satu penyakit mata yang dapat menyebabkan kebutaan permanen apabila tidak terdeteksi dan ditangani sejak dini. Namun, proses identifikasi glaukoma melalui citra retina masih menghadapi berbagai kendala karena perbedaan antara retina glaukoma dan non-glaukoma sering kali sulit dikenali secara visual, serta membutuhkan pengalaman dari tenaga medis yang melakukan pemeriksaan. Di sisi lain, perkembangan teknologi kecerdasan buatan membuka peluang untuk membantu proses klasifikasi citra medis secara otomatis. Berdasarkan kondisi tersebut, rumusan masalah dalam penelitian ini adalah bagaimana membangun model klasifikasi glaukoma pada citra retina menggunakan MobileNetV3 sebagai feature extraction dan Multilayer Perceptron (MLP) sebagai classifier, serta bagaimana kemampuan model tersebut dalam membedakan citra retina glaukoma dan non-glaukoma berdasarkan hasil evaluasi yang diperoleh. Tujuan Penelitian Penelitian ini bertujuan untuk mengembangkan model klasifikasi glaukoma pada citra retina dengan memanfaatkan MobileNetV3 sebagai feature extraction dan Multilayer Perceptron (MLP) sebagai classifier. Selain itu, penelitian ini juga bertujuan untuk menerapkan tahapan preprocessing pada dataset citra retina yang berasal dari beberapa sumber, kemudian melatih model agar mampu mengenali pola yang berkaitan dengan glaukoma secara otomatis. Melalui penelitian ini diharapkan dapat diperoleh model yang mampu membedakan citra retina glaukoma dan non-glaukoma dengan performa yang baik, sehingga dapat menjadi salah satu bentuk pemanfaatan kecerdasan buatan dalam mendukung proses deteksi dini glaukoma berbasis citra retina.
Metodologi	
Ringkasan dataset	Penelitian ini menggunakan gabungan dari 3 dataset citra retina, yaitu Hillel-Yaffe Glaucoma Dataset, G1020, dan ORIGA. Ketiga dataset dipilih karena memiliki citra fundus retina dengan label klasifikasi glaukoma dan non-glaukoma sehingga sesuai untuk proses pembelajaran model deep learning. Dataset Hillel-Yaffe terdiri dari 747 citra retina dengan distribusi 548 citra glaukoma dan 199 citra non glaukoma. Dataset ini juga menyediakan atribut tambahan berupa quality score yang menunjukkan kualitas citra retina. Dataset G1020 terdiri dari 1020 citra retina dengan label biner glaukoma dan non-glaukoma. Sementara itu, dataset ORIGA terdiri dari 650 citra retina dengan distribusi 168 citra glaukoma dan 482 citra normal.


	Seluruh citra retina menggunakan format gambar .jpg dengan representasi warna RGB dan rasio gambar 1:1. Resolusi gambar pada setiap dataset bervariasi sehingga diperlukan proses standarisasi ukuran citra sebelum digunakan pada tahap pelatihan model. Setelah seluruh dataset digabungkan dan melalui proses validasi data, diperoleh total 2417 citra retina yang terdiri dari 1405 citra non glaukoma dan 1012 citra glaukoma. Dataset retina memiliki karakteristik yang bervariasi dan terdapat ketidakseimbangan distribusi kelas. Variasi ini menjadi tantangan tersendiri dalam proses klasifikasi sehingga diperlukan preprocessing dan augmentasi citra untuk meningkatkan kualitas fitur retina.
Alur penelitian	Link Ilustrasi Flowchart dapat diakses disini. 1. <i>Pengumpulan Dataset</i> Penelitian dimulai dengan mengumpulkan data citra fundus retina dari tiga sumber dataset, yaitu ORIGA, G1020, dan HYGD (Hillel Yaffe Glaucoma Dataset). Penggunaan beberapa dataset bertujuan meningkatkan jumlah data serta keragaman karakteristik citra retina sehingga model dapat mempelajari pola glaukoma secara lebih baik. 2. <i>Merge Dataset</i> Seluruh dataset digabungkan ke dalam satu struktur data yang seragam. Pada tahap ini dilakukan penyamaan nama kolom, format metadata, dan representasi label sehingga seluruh data dapat diproses menggunakan pipeline yang sama. 3. <i>Cleaning dan Standardisasi Data</i> Proses yang dilakukan meliputi menghapus data duplikat, menstandarkan nama file gambar, mengonversi label glaukoma menjadi format biner (0 = normal, 1 = glaukoma), memeriksa keberadaan file citra, menyesuaikan ukuran dan format metadata. 4. <i>Validasi Kualitas Data</i> Data yang telah dibersihkan kemudian diperiksa kembali untuk memastikan seluruh gambar dapat diakses dan memiliki label yang sesuai. Tahap ini meliputi deteksi data yang hilang (missing value), pemeriksaan inkonsistensi label, dan penghapusan data yang tidak valid. 5. <i>Analisis Distribusi Dataset</i> Sebelum pelatihan model dilakukan analisis distribusi kelas untuk mengetahui proporsi data glaukoma dan non-glaukoma. Analisis ini membantu mengidentifikasi potensi ketidakseimbangan kelas (class imbalance) yang dapat mempengaruhi performa model. 6. <i>Split Dataset</i> Dataset dibagi menjadi tiga subset: Training set, Validation set, dan Testing set. Pembagian dilakukan menggunakan stratified split sehingga proporsi kelas pada masing-masing subset tetap terjaga. 7. <i>Preprocessing Citra Retina</i> Pada tahap ini, citra terlebih dahulu dikonversi ke format warna yang sesuai untuk pengolahan lebih lanjut, kemudian seluruh gambar diubah ukurannya menjadi 224×224 piksel agar sesuai dengan kebutuhan input arsitektur MobileNetV3. Selanjutnya dilakukan ekstraksi kanal hijau (green channel) karena kanal ini mampu menampilkan struktur pembuluh darah dan area retina dengan kontras yang lebih jelas dibandingkan kanal warna lainnya. Setelah itu, metode Contrast Limited Adaptive Histogram Equalization (CLAHE) diterapkan untuk meningkatkan kontras lokal sehingga detail penting pada retina menjadi lebih mudah dikenali. Tahap terakhir adalah


	normalisasi nilai piksel menggunakan parameter ImageNet untuk menghasilkan distribusi data yang lebih stabil. 8. <i>Data Augmentation</i> Untuk meningkatkan variasi data pelatihan dan mengurangi overfitting, dilakukan augmentasi citra. Teknik yang digunakan yaitu Horizontal Flip, Vertical Flip, Random Resized Crop, Random Rotation, Color Adjustment, Coarse Dropout. 9. <i>Pembuatan Dataset dan DataLoader</i> Citra yang telah diproses dikonversi ke tensor PyTorch kemudian dimuat menggunakan DataLoader. 10. <i>Pemodelan</i> Model yang digunakan adalah MobileNetV3 dan MLP Classifier. MobileNetV3 digunakan sebagai feature extractor untuk mengekstraksi karakteristik penting dari citra retina. Sedangkan MPL Classifier digunakan untuk melakukan klasifikasi berdasarkan fitur yang dihasilkan oleh MobileNetV3. 11. <i>Konfigurasi Training</i> Sebelum proses pelatihan model dilakukan, ditetapkan beberapa parameter training yang meliputi optimizer AdamW, learning rate sebesar 1×10^{-4}, batch size 16, jumlah epoch sebanyak 30, scheduler CosineAnnealingLR, serta fungsi loss CrossEntropyLoss. 12. <i>Training dan Validation</i> Model dilatih menggunakan data training dan dievaluasi secara berkala menggunakan data validation. Pada tahap ini dilakukan Forward propagation, perhitungan loss, backpropagation, update bobot, dan monitoring performa validation 13. <i>Evaluasi Model</i> Model yang telah dilatih dievaluasi menggunakan data testing. Metrik evaluasi yang digunakan meliputi accuracy, precision, recall, F1-Score, dan AUC. Metrik tersebut digunakan untuk mengukur kemampuan model dalam membedakan citra retina glaukoma dan non-glaukoma.
Proses wrangling	1. <i>Load Dataset</i> <pre>origa_df = pd.read_csv("origa_info.csv") g1020_df = pd.read_csv("G1020.csv") labels_df = pd.read_csv("Labels glaukoma.csv")</pre> Tahap awal data wrangling dilakukan dengan mengumpulkan data dari beberapa dataset glaukoma yang berbeda, yaitu ORIGA, G1020, dan Glaukoma Dataset. Setiap dataset memiliki format penyimpanan, nama kolom, dan representasi label yang berbeda 2. <i>Standardisasi Nama Kolom dan Label</i> <pre>origa_df = origa_df[['Image', 'Label']] origa_df.columns = ['image', 'label'] g1020_df = g1020_df[['imageID', 'binaryLabels']] g1020_df.columns = ['image', 'label'] labels_df = labels_df[['Image Name', 'Label']] labels_df['Label'] = labels_df['Label'].replace({ 'GON+': 1, 'GON-': 0})</pre>

	<pre>labels_df.columns = ['image', 'label']</pre> Dilakukan penyeragaman struktur dataset dengan menyamakan nama kolom yang merepresentasikan identitas citra dan label kelas. Selain itu, label kategorikal yang masih berupa teks dikonversi ke format numerik biner agar sesuai dengan kebutuhan proses pelatihan model klasifikasi. 3. Merge Dataset <pre>df = pd.concat([origa_df, g1020_df, labels_df], ignore_index=True)</pre> Seluruh dataset yang telah memiliki struktur seragam kemudian digabungkan menjadi satu dataset terpadu. Langkah ini bertujuan untuk meningkatkan jumlah data yang tersedia sehingga model dapat mempelajari karakteristik citra glaukoma dari sumber yang lebih beragam. 4. Validasi dan Pencocokan File Gambar <pre>df['filepath'] = df['image'].apply(get_image_path) df = df[df['filepath'].notnull()].reset_index(drop=True)</pre> Melakukan pencocokan antara data label dengan file citra yang tersedia pada direktori penyimpanan. Data yang tidak memiliki pasangan file citra yang valid dihapus dari dataset untuk mencegah terjadinya kesalahan saat proses preprocessing maupun pelatihan model. 5. Analisis Distribusi Kelas <pre>df['label'].value_counts()</pre> Dilakukan pemeriksaan distribusi kelas untuk mengetahui proporsi jumlah citra glaukoma dan non-glaukoma. Analisis ini penting untuk mengidentifikasi potensi ketidakseimbangan kelas yang dapat memengaruhi performa model klasifikasi. 6. Split Dataset <pre>df_trainval, df_test = train_test_split(df, test_size=0.15, stratify=df['label'])</pre> Dataset yang telah bersih dibagi menjadi data pelatihan (training), validasi (validation), dan pengujian (testing). Pembagian dilakukan menggunakan metode stratified sampling agar proporsi masing-masing kelas tetap terjaga pada setiap subset data. 7. Preprocessing Citra Retina <pre>img = cv2.cvtColor(img, cv2.COLOR_BGR2RGB) img = cv2.resize(img, (224,224)) clahe = cv2.createCLAHE(clipLimit=4.0, tileGridSize=(8,8))</pre> Citra retina mengalami preprocessing berupa konversi warna, perubahan ukuran citra menjadi 224×224 piksel, serta peningkatan kontras pada kanal hijau menggunakan metode CLAHE (Contrast Limited Adaptive Histogram Equalization). Kanal hijau dipilih karena mampu menampilkan struktur pembuluh darah dan area retina dengan lebih jelas.
--	---

	8. <i>Augmentasi Data</i> <i>A.RandomResizedCrop(...)</i> <i>A.HorizontalFlip(...)</i> <i>A.VerticalFlip(...)</i> <i>A.ShiftScaleRotate(...)</i> <i>A.HueSaturationValue(...)</i> <i>A.CoarseDropout(...)</i> Untuk meningkatkan keragaman data pelatihan dan mengurangi risiko overfitting, dilakukan augmentasi citra menggunakan berbagai transformasi seperti cropping, flipping, rotasi, perubahan warna, CLAHE tambahan, serta Coarse Dropout. 9. <i>Normalisasi dan Konversi Tensor</i> <i>A.Normalize(mean=IMAGENET_MEAN, std=IMAGENET_STD)</i> <i>ToTensorV2()</i> Citra yang telah diproses kemudian dinormalisasi menggunakan nilai mean dan standar deviasi ImageNet, lalu dikonversi ke format tensor agar dapat diproses oleh model deep learning berbasis PyTorch. 10. <i>Pembuatan Dataset dan DataLoader</i> <i>train_loader = DataLoader(...)</i> <i>val_loader = DataLoader(...)</i> <i>test_loader = DataLoader(...)</i> Membangun objek dataset dan DataLoader untuk mengatur proses pembacaan data, batching, serta pengacakan data selama pelatihan model.
Proses rekayasa fitur	Seluruh citra retina terlebih dahulu di-resize menjadi ukuran 224×224 piksel agar sesuai dengan ukuran input pada arsitektur MobileNetV3. Standarisasi ukuran citra diperlukan untuk menjaga konsistensi dimensi input selama proses pelatihan model deep learning serta mengurangi kompleksitas komputasi. Selain itu, ukuran 224×224 merupakan ukuran input standar yang umum digunakan pada model pretrained berbasis ImageNet, termasuk MobileNetV3. Menurut penelitian Son et al. (2021), standarisasi ukuran citra retina menjadi langkah penting untuk menjaga stabilitas ekstraksi fitur dan meningkatkan efisiensi proses klasifikasi citra fundus retina. Setelah proses resize, dilakukan konversi warna dari format BGR ke RGB. Proses ini dilakukan karena library OpenCV secara default membaca citra menggunakan format BGR, sedangkan model pretrained ImageNet dilatih menggunakan representasi warna RGB. Ketidaksesuaian format warna dapat menyebabkan distribusi fitur visual menjadi tidak optimal sehingga mempengaruhi performa model klasifikasi. Tahap preprocessing berikutnya adalah ekstraksi green channel. Green channel dipilih karena mampu menampilkan struktur pembuluh darah retina, optic disc, serta area saraf optik dengan kontras yang lebih jelas dibandingkan kanal merah maupun biru. Pada citra fundus retina, kanal hijau memiliki sensitivitas yang lebih baik


	terhadap detail vaskular dan tekstur retina sehingga sering digunakan dalam penelitian klasifikasi penyakit mata berbasis computer vision. Penelitian Naser et al. (2023) menunjukkan bahwa penggunaan green channel extraction mampu meningkatkan kualitas representasi fitur retina dan membantu model deep learning dalam mendeteksi pola abnormalitas pada citra fundus. Setelah ekstraksi green channel, diterapkan metode Contrast Limited Adaptive Histogram Equalization (CLAHE) untuk meningkatkan kontras lokal citra retina. CLAHE bekerja dengan memperbaiki distribusi intensitas piksel secara adaptif pada area-area tertentu sehingga detail struktur retina, seperti optic cup dan optic disc, menjadi lebih jelas terlihat. Teknik ini juga membantu mengurangi pengaruh pencahayaan yang tidak merata pada citra retina. Menurut Son et al. (2021), penerapan CLAHE pada citra fundus retina terbukti mampu meningkatkan visibilitas fitur anatomis retina dan meningkatkan performa klasifikasi penyakit mata berbasis deep learning. Proses normalisasi dilakukan menggunakan nilai mean dan standard deviation ImageNet. Normalisasi bertujuan menyesuaikan distribusi nilai piksel citra retina dengan distribusi data pada model pretrained ImageNet sehingga proses transfer learning dapat berjalan lebih optimal. Pendekatan ini banyak digunakan dalam penelitian deep learning karena mampu mempercepat proses konvergensi model dan meningkatkan stabilitas training (Naser et al., 2023). Pada tahap augmentasi data digunakan beberapa transformasi citra, yaitu HorizontalFlip, VerticalFlip, RandomResizedCrop, ShiftScaleRotate, HueSaturationValue, dan CoarseDropout. Teknik augmentasi digunakan untuk meningkatkan variasi data training serta membantu model mengenali pola retina pada berbagai kondisi pencahayaan, orientasi, posisi, dan kualitas gambar. Selain itu, augmentasi juga berfungsi untuk mengurangi risiko overfitting akibat keterbatasan jumlah data medis. Penelitian Gour & Khanna (2022) menjelaskan bahwa augmentasi citra fundus retina dapat meningkatkan kemampuan generalisasi model CNN dalam klasifikasi glaukoma dan membantu model lebih robust terhadap variasi visual pada dataset retina. Model utama yang digunakan dalam penelitian ini adalah MobileNetV3 sebagai feature extractor dan Multilayer Perceptron (MLP) sebagai classifier. Arsitektur ini menggunakan kombinasi depthwise separable convolution, squeeze-and-excitation block, dan optimasi neural architecture search sehingga cocok digunakan pada perangkat dengan keterbatasan sumber daya komputasi. Penelitian Gour & Khanna (2022) menunjukkan bahwa arsitektur lightweight CNN mampu menghasilkan performa kompetitif pada klasifikasi penyakit retina dengan kebutuhan komputasi yang lebih rendah dibandingkan CNN konvensional. Penggunaan model pretrained ImageNet memungkinkan proses transfer learning sehingga model dapat memanfaatkan representasi fitur visual yang telah dipelajari sebelumnya. Transfer learning menjadi pendekatan yang penting dalam klasifikasi citra medis karena jumlah dataset medis umumnya terbatas dibandingkan dataset natural image. Menurut Diaz-Pinto et al. (2021), penggunaan pretrained model secara signifikan membantu peningkatan performa klasifikasi retina terutama pada kondisi dataset yang relatif kecil dan tidak seimbang. Focal Loss digunakan sebagai fungsi loss utama untuk menangani ketidakseimbangan kelas pada dataset retina. Fungsi loss ini bekerja dengan memberikan fokus lebih besar pada sampel yang sulit diklasifikasikan sehingga model tidak terlalu bias terhadap kelas mayoritas. Penggunaan Focal Loss pada
--	--

	<i>klasifikasi penyakit mata terbukti efektif dalam meningkatkan sensitivitas model terhadap kelas minoritas glaukoma (Naser et al., 2023).</i> <i>Optimizer AdamW digunakan karena mampu memperbarui parameter model secara efektif dan menjaga proses pelatihan tetap stabil. Sementara itu, CosineAnnealingLR digunakan untuk mengatur nilai learning rate agar semakin kecil secara bertahap selama training. Dengan cara ini, model dapat belajar lebih baik dan menghasilkan performa yang lebih optimal pada akhir pelatihan.</i>						
Temuan	<i>Dari berbagai proses yang kami lakukan, diperoleh beberapa insight penting. Penggabungan dataset dari berbagai sumber meningkatkan variasi karakteristik retina sehingga model memiliki kemampuan generalisasi yang lebih baik. Proses preprocessing green channel dan CLAHE meningkatkan kontras area saraf optik sehingga fitur retina lebih mudah dipelajari.</i> <i>Penggunaan augmentasi data membantu meningkatkan stabilitas performa model pada data validation. Selain itu, ketidakseimbangan distribusi kelas terbukti mempengaruhi proses klasifikasi sehingga penggunaan Focal Loss menjadi penting untuk membantu model lebih fokus pada kelas minoritas.</i>						
Hasil dan Pembahasan							
Hasil eksplorasi data	 <table border="1"> <caption>Data for Gambar 1. Distribusi dataset</caption> <thead> <tr> <th>label</th> <th>count</th> </tr> </thead> <tbody> <tr> <td>0</td> <td>1405</td> </tr> <tr> <td>1</td> <td>1012</td> </tr> </tbody> </table> <i>Grafik distribusi dataset menunjukkan bahwa jumlah citra retina kelas non-glaukoma (label 0) lebih banyak dibandingkan kelas glaukoma (label 1). Dataset terdiri dari sekitar 1405 citra non-glaukoma dan 1012 citra glaukoma. Ini menunjukkan adanya kondisi class imbalance. Kondisi imbalance dapat menyebabkan model cenderung belajar dikelas mayoritas sehingga berpotensi menurunkan kemampuan klasifikasi. Oleh karena itu, penelitian ini menggunakan pendekatan seperti Focal Loss dan augmentasi data untuk membantu model lebih fokus dalam mempelajari karakteristik kelas minoritas serta meningkatkan kemampuan generalisasi model.</i>	label	count	0	1405	1	1012
label	count						
0	1405						
1	1012						



Gambar 2. Before after preprocessing

Hasil visualisasi menunjukkan bahwa proses preprocessing berhasil meningkatkan kualitas citra retina pada kedua kelas, baik glaukoma maupun non-glaukoma. Setelah preprocessing, detail struktur retina seperti pembuluh darah, optic disc, dan area saraf optik terlihat lebih jelas dibandingkan citra asli. Penerapan ekstraksi green channel dan CLAHE meningkatkan kontras lokal citra sehingga area retina yang sebelumnya gelap atau kurang tajam menjadi lebih mudah diamati. preprocessing membantu memperjelas area optic cup dan pembuluh darah yang berkaitan dengan kerusakan saraf optik serta pola pembuluh darah retina terlihat lebih tegas dan merata.



Gambar 3. Plot Metrik Evaluasi

Berdasarkan grafik performa training, model menunjukkan peningkatan performa yang konsisten selama proses pelatihan. Nilai accuracy, precision, F1-score, dan AUC mengalami peningkatan seiring bertambahnya epoch, sedangkan nilai loss mengalami penurunan dan stabil pada epoch akhir. Nilai AUC yang mencapai 0.8249 menunjukkan bahwa model memiliki kemampuan yang baik dalam membedakan citra glaucoma dan non-glaucoma. Selain itu, tidak ditemukan indikasi overfitting yang signifikan karena validation loss tetap stabil hingga akhir pelatihan.

Hasil eksperimen

METRIK	NILAI
Accuracy	0.7735
Precision	0.7652
Recall	0.6645
F1-Score	0.7113
AUC	0.8249

Tabel 1. Hasil Metrik Evaluasi (Terbaik)

Berdasarkan hasil evaluasi, model klasifikasi glaucoma menunjukkan performa yang cukup baik dalam membedakan citra glaucoma dan non-glaucoma. Nilai accuracy menunjukkan bahwa model mampu melakukan klasifikasi dengan tingkat ketepatan yang baik, sedangkan nilai precision mengindikasikan bahwa sebagian besar citra yang diprediksi sebagai glaucoma memang merupakan glaucoma. Nilai recall menunjukkan bahwa model telah mampu mendeteksi sebagian besar kasus glaucoma meskipun masih terdapat beberapa kasus yang belum teridentifikasi secara optimal. Nilai F1-score memperlihatkan keseimbangan yang cukup baik antara precision dan recall, sehingga model dapat dikatakan memiliki performa klasifikasi yang stabil. Selain itu, Nilai AUC yang berada di atas 0.8 menunjukkan bahwa model memiliki kemampuan yang baik dalam membedakan citra glaucoma dan non-glaucoma

Kesimpulan dan Saran

Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, proyek klasifikasi glaukoma menggunakan MobileNetV3 dan Multilayer Perceptron (MLP) mampu memberikan kontribusi dalam membantu proses deteksi dini glaukoma melalui citra retina secara otomatis. Model yang dikembangkan menunjukkan kemampuan yang cukup baik dalam membedakan citra retina glaukoma dan non-glaukoma berdasarkan hasil

	evaluasi yang diperoleh. Selain itu, penerapan preprocessing seperti green channel extraction dan CLAHE terbukti membantu memperjelas struktur retina sehingga fitur penting lebih mudah dipelajari oleh model. Penggunaan transfer learning juga membantu meningkatkan performa klasifikasi meskipun jumlah dataset medis relatif terbatas. Temuan dari penelitian ini menunjukkan bahwa pemanfaatan kecerdasan buatan dapat digunakan sebagai alat bantu pendukung dalam proses skrining awal glaukoma sehingga diharapkan dapat membantu meningkatkan kesadaran terhadap pentingnya deteksi dini penyakit mata. Bagi masyarakat, sistem seperti ini berpotensi membantu proses pemeriksaan retina menjadi lebih cepat, objektif, dan mudah diakses, terutama pada kondisi dengan keterbatasan tenaga medis atau fasilitas pemeriksaan mata.
Saran	Berdasarkan penelitian yang telah dilakukan, terdapat beberapa saran yang dapat dikembangkan pada penelitian berikutnya. Penelitian selanjutnya dapat menggunakan jumlah dataset yang lebih besar dan lebih beragam agar model mampu mempelajari karakteristik retina secara lebih luas dan meningkatkan kemampuan generalisasi model. Selain itu, proses preprocessing dan augmentasi citra dapat dikembangkan lebih lanjut untuk meningkatkan kualitas fitur retina yang dipelajari oleh model. Penelitian berikutnya juga dapat mencoba kombinasi parameter training yang berbeda, seperti pengaturan learning rate, batch size, optimizer, maupun jumlah epoch untuk memperoleh performa model yang lebih optimal. Selain itu, pengujian menggunakan data klinis atau data retina dari rumah sakit juga dapat dilakukan agar model dapat dievaluasi pada kondisi data yang lebih nyata dan bervariasi. Pengembangan sistem berbasis web atau mobile juga dapat menjadi langkah lanjutan sehingga model klasifikasi glaukoma dapat dimanfaatkan secara lebih praktis sebagai alat bantu skrining awal penyakit mata.
Daftar Pustaka	
Daftar Pustaka	Diaz-Pinto, A., Morales, S., Naranjo, V., Köhler, T., Mossi, J. M., & Navea, A. (2021). CNNs for automatic glaucoma assessment using fundus images: An extensive validation. <i>Scientific Reports</i>, 11(1), 8251. https://doi.org/10.1038/s41598-021-81554-4 Gour, N., & Khanna, P. (2022). Multi-class multi-label ophthalmological disease detection using transfer learning based convolutional neural network. <i>Scientific Reports</i>, 12(1), 27045. https://doi.org/10.1038/s41598-022-27045-6 Naser, M. A., Hameed, B. M., & Hasan, M. K. (2023). Deep learning framework for retinal disease classification using enhanced fundus images. <i>IEEE Access</i>, 11, 134291–134305. https://doi.org/10.1109/ACCESS.2023.3342910 Son, J., Shin, J. Y., Kim, H. D., Jung, K. H., Park, K. H., & Park, S. J. (2021). Development and validation of deep learning models for screening multiple abnormal findings in retinal fundus images. <i>Scientific Reports</i>, 11(1), 21154. https://doi.org/10.1038/s41598-021-99605-1